能凭统计指纹分开「同一谱系」的散文吗？——以逻辑回归区分汪曾祺与李娟

一、引言

汪曾祺与李娟常被放进同一条谱系：都写草木、饮食、家人与劳作，都用近乎口语的白描在平淡中见奇趣，李娟甚至被称为「汪曾祺一脉的传人」。这类判断依赖批评家的直觉，而直觉可以被操作化：把「这段文字出自谁手」变成二元分类任务，让机器只凭表层特征作答，再回头检验印象。这道题比课堂上的情感分类更有意思之处在于「像」：两位作家题材高度重叠，只靠题材词汇的分类器必然失效，必须捕捉更细的东西——虚词的习惯、句子的节奏、标点的偏爱。本文用一千余个自然段训练逻辑回归分类器回答它，并追问每一次预测：模型究竟在看什么。

二、标签定义与资料

标签「汪曾祺 / 李娟」采用版本出处标准：段落出自哪位作家的已出版作品就标注为谁，避免「读起来像谁」的主观性。文本单位取自然段（30–600 字，超长者在句末切成 ≤500 字片段），每篇至多贡献 40 段；段落是「风格可感」的最小完整单位——整篇太长则样本不足，单句太短则丢失节奏。

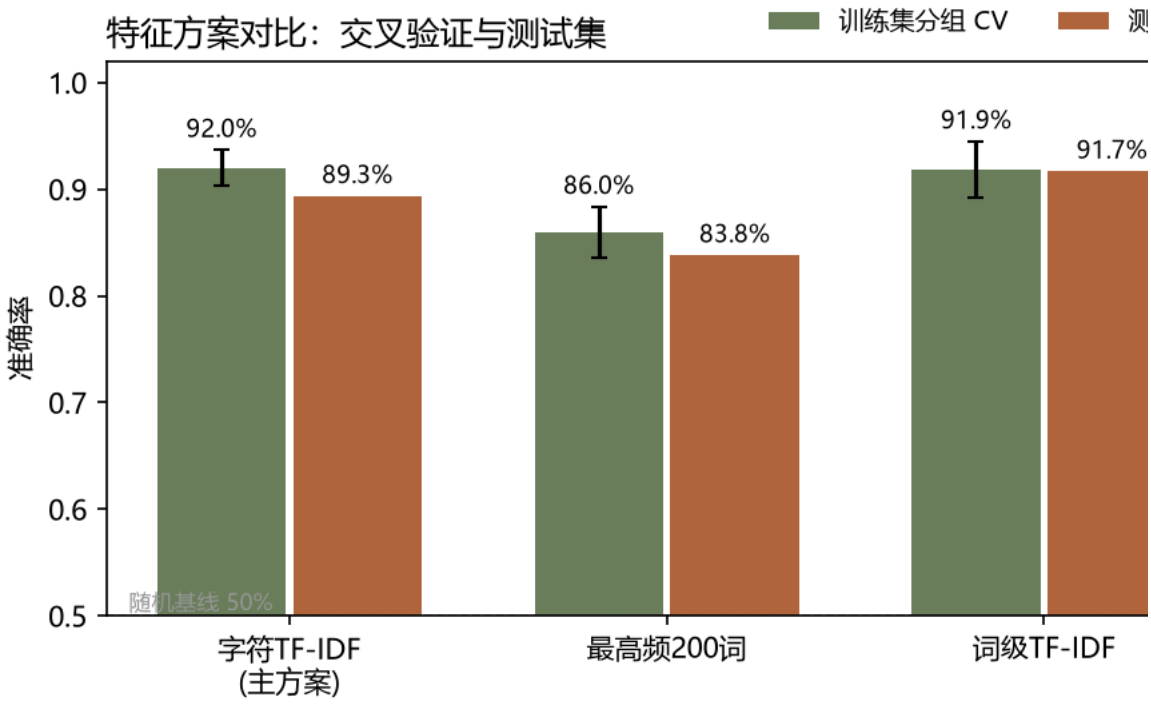
汪曾祺语料取自 GitHub 公开的《汪曾祺全集》文字版（OCR 数据）散文卷两卷，共 196 篇。李娟作品仍在版权期内，语料采自人民周刊、中国作家网、QQ 阅读免费版等官方渠道的全文转载页（来源逐页记录于仓库清单）；混入的「关于作家的报道」与作者简介等样板段均已人工剔除。清洗的关键一步是统一标点全半角：汪曾祺语料来自纸书扫描（半角），李娟来自网页（全角）——否则模型学到的第一「指纹」将是标点宽度这种与文风无关的假特征。此外还去除网址乱码、中文占比过低的段落，并做精确去重。清洗后汪曾祺 2,989 段、李娟 647 段；对多数类下采样平衡后共 1,064 段（每类 532），训练集 848 段、测试集 216 段，满足每类不少于 200 笔、两类平衡的要求。

三、切分与特征

切分是最容易失守的环节。我们以「篇」而非「段」为单位做 80/20 切分（按作者分层、种子 42）：同一篇的段落只能整体进训练集或测试集——同篇段落彼此相似，随机撒开等于让模型考前见过原题的孪生兄弟。对照实验证实了担忧：按段随机切分可得 95.3%，按篇切分 89.3%，六个百分点的差额就是「泄漏税」。

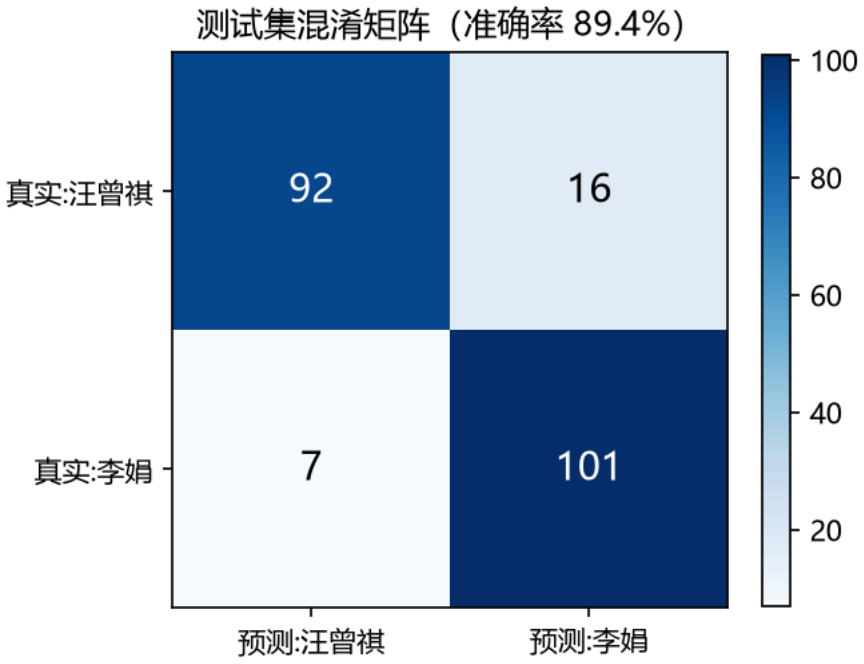
特征选择同样只在训练集内完成：三种候选（字符 1–2 元 TF-IDF、最高频 200 词词频、词级 TF-IDF）先做五折交叉验证，且 CV 本身也按「篇」分组。这一步我们付过学费：普通交叉验证把同篇段落分进训练折与验证折，报出虚高的 93.1%，改按篇分组后回落到 92.0%。最终选定字符级 TF-IDF 为主方案（分组交叉验证 92.0%±1.7%）。TF-IDF 的直觉是「本段常见、他处少见」的字才有区分力，处处出现的「的」「了」被自动压低；以字符二元组代替词语，则无需分词器即可捕捉「俺们」「了罢」这类搭配，对分词器的选择也不敏感——几乎打平的词级 TF-IDF（91.9%±2.6%）就高度依赖分词质量。模型即课堂所学的逻辑回归：特征加权求和得到分数，经 S 形函数转为「属于李娟」的概率，训练即调整权重、使预测贴近真实标签。

特征方案	训练集分组交叉验证	测试集
字符 1–2 元 TF-IDF（主方案）	92.0% ± 1.7	89.3%
最高频 200 词词频	86.0% ± 2.4	83.8%
词级 TF-IDF（jieba）	91.9% ± 2.6	91.7%



四、测试集结果

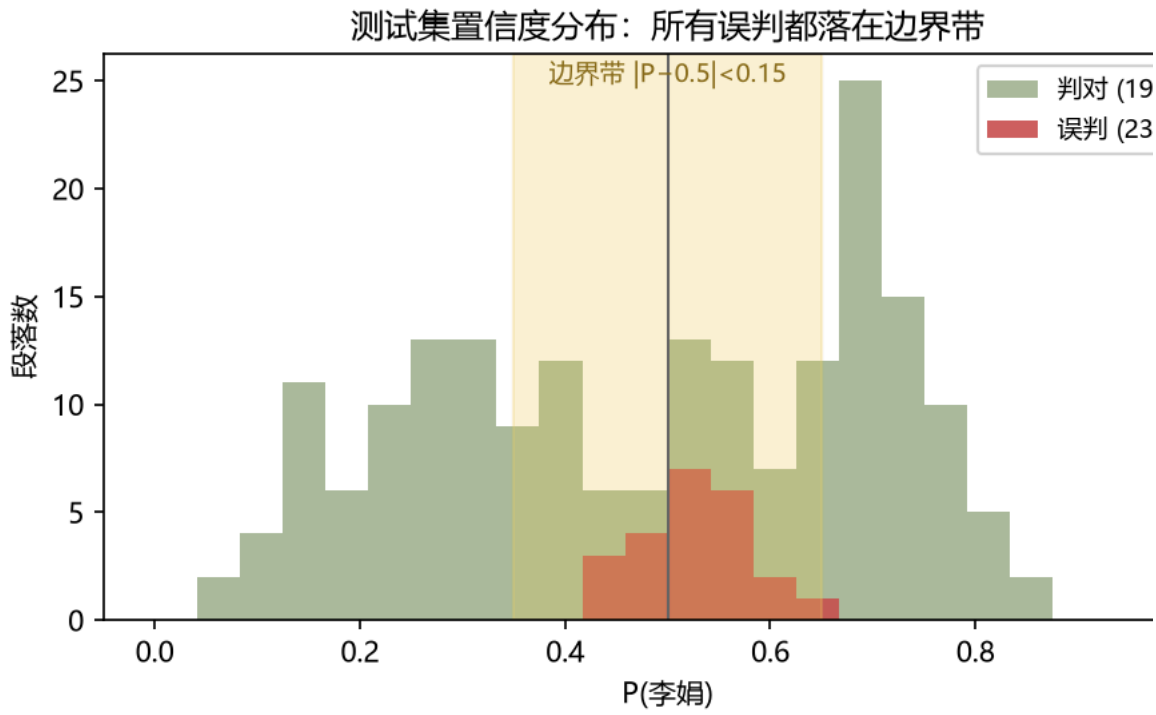
在 216 段测试集上，准确率为 89.3%（均衡随机基线 50%）。混淆矩阵显示：汪曾祺 108 段中 92 段判对、16 段误判为李娟；李娟 108 段中 102 段判对、6 段误判为汪曾祺。逐类来看，汪曾祺精确率 0.929、召回率 0.852；李娟 0.863、0.935。把段落投票回文章、按篇内多数决再算，41 篇测试文章的文章级准确率升至 92.7%——单段拿不准的边界文字，整篇多能被多数票校正。错误并不对称：模型「认出」李娟的能力（召回率 93.5%）强于汪曾祺（85.2%）。合理的解释是李娟文风更整齐可辨，而汪曾祺语料跨近五十年、含谈艺文字，内部异质性更大，更多段落游移到「李娟侧」。



五、错误分析

全部 23 个误判有一处惊人的共性：置信度统统落在 |P−0.5|<0.15 的边界带内（图三）——模型没有一次「自信地犯错」。错误不是随机噪音，而是风格空间交叠地带的地图。

按篇汇总看清走向。汪曾祺一侧的错误集中于他最「白描」的游记与生活篇目：〈滇游新记〉4 段、〈冬天〉3 段、〈夏天的昆虫〉与〈新校舍〉各 2 段。〈冬天〉「放了寒假，就可以睡懒觉。棉衣在铜炉子上烘过了……棉鞋烘得热热的，穿进去真是舒服」一段，被以 0.62 的概率判给李娟——口语短句、生活小物、不着一句抒情，与李娟的白描几乎同构，人类读者恐怕也要犹豫。李娟一侧的最大来源是《记一忘三二》代自序（5 段）——她谈阅读与写作的文字，题材恰好伸进汪曾祺谈艺文的领地。两个方向指向同一结论：写「生活」时两人像，写「文学」时也像——误判本身就是谱系亲缘的定量证据。

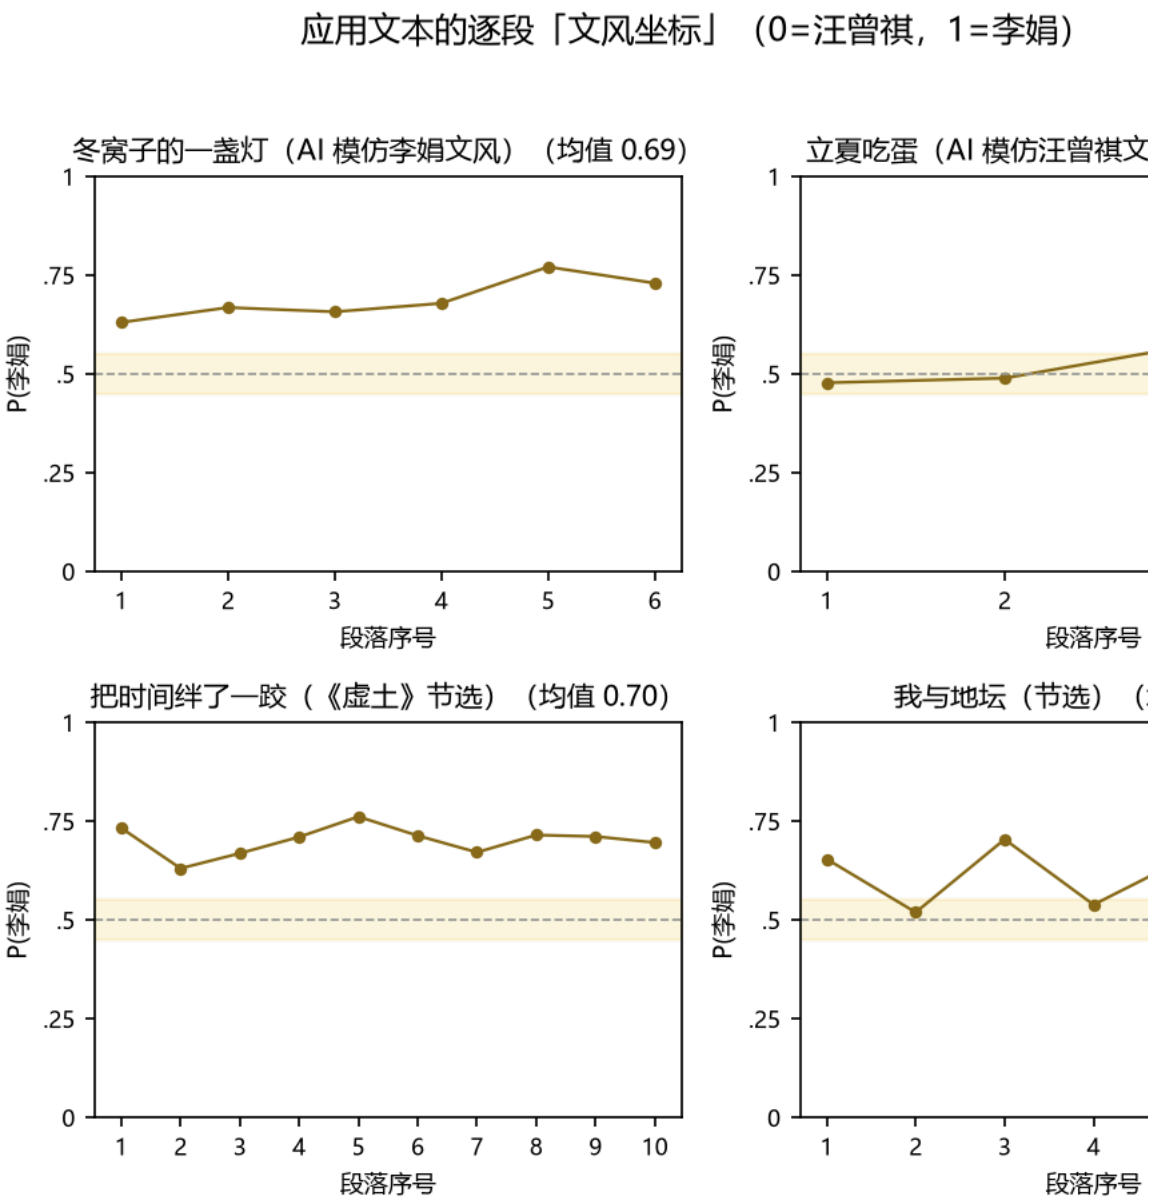


六、应用到训练资料之外

把模型用于训练资料之外的文本，逐段输出「属于李娟」的概率并对全篇取平均：史铁生《我与地坛》节选 0.580，刘亮程〈把时间绊了一跤〉0.702。另有两组 AI 探测文本（按两位作家的语言习惯生成，试验设计在此如实声明）——模仿李娟者得 0.690，通过「测谎」；模仿汪曾祺者 0.505，恰好压线。

对这组读数需要三重克制。其一，它们全部落在 0.50–0.70 的中间地带：模型对分布外文本自动犹豫，这不是缺陷而是诚实——训练集只提供两个坐标点，新文本的概率只是这两点连线上的投影。其二，「更像谁」不等于「是谁」——刘亮程读数最靠李娟，只因他同样书写新疆荒野；预测揭示的是风格亲缘，而非作者身份。其三，AI 模仿实验最耐人寻味：模仿李娟者复制的正是模型权重最大的表层特征（省略号、破折号、「我妈」「外婆」），轻松过关；模仿汪曾祺者反而露馅。可见分类器捕捉的是表面统计特征而非文学性，对人能察觉的「AI 味」几乎免疫——它只能提供参照，不能代替鉴别。

应用文本	平均 P(李娟)	多数预测
史铁生《我与地坛》节选	0.580	偏李娟
刘亮程〈把时间绊了一跤〉	0.702	偏李娟
AI 模仿汪曾祺文风（自制）	0.505	恰在边界
AI 模仿李娟文风（自制）	0.690	偏李娟



七、稳健性检验与限制

系数表顶端提醒我们警惕：推向李娟的特征里既有文体指纹（省略号、破折号、语气词），也有题材词（葵、牧、大地）与亲属称谓（外婆、我妈）。模型依赖哪一层？两个对照实验给出回答。其一，把人名、地名等专名遮蔽后重训，准确率 88.9%，与基线 89.3% 几乎无异——模型并未靠专名作弊。其二，只用约 120 个虚词的每千字频率做 z 分数标准化（经典文体计量学的做法），准确率仍有 75.0%——不含题材词的纯文体指纹本身就是强信号。三个实验合起来的结论：模型调用的是多层冗余的信息，其中文体部分足以支撑大部分正确率。

限制也应言明：语料管道不同（纸书 OCR 与网页转载），OCR 错字可能成为可学习的痕迹；李娟可用整书太少，同集子内篇章共享题材词汇，按篇切分无法消除「书内泄漏」；段落级结论不能直接推广到整篇或整书。后续可扩充李娟语料（如《羊道》三部曲）、引入第三位作家把封闭二分改为开放集、用逐段归因检视预测的证据。

八、结语

这个小分类器没有推翻「李娟承接汪曾祺」的文学史直觉；恰恰相反，它把直觉变成可以测量、可以出错、也可以复核的对象——相似的是题材与姿态，可分的是句子层面的统计指纹，而误判整齐地堆在边界上，正是亲缘最诚实的定量形态。对「用机器读文学」的合理态度由此而来：让机器提供参照与追问，把判断留给人。